# クラスタサイズ調整変数を導入したクラスタリング手法の評価

**池辺 颯一**

**芝浦工業大学 工学部 通信工学科**

2018 年 1 月 16 日

# 概要・背景

- 情報化社会の発展によりデータが複雑かつ膨大に
- ビッグデータを人の手で分類するのは難しい
- それらのデータを自動的に分類するクラスタリングに着目

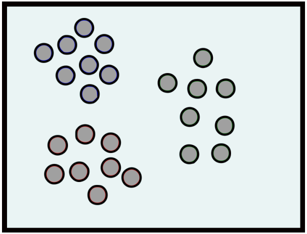

クラスタリング前

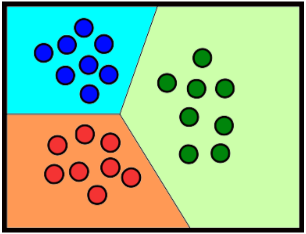

クラスタリング後

# 目的・目標

## 目的

-

## 目標

-

# 実験対象

## 提案手法

- eFCMA
- qFCMA
- sFCMA

# 研究評価方法

1.

# クラスタリングの最適化問題

## eFCMA

$$\underset{u,v,\alpha}{\text{minimize}} \sum_{i=1}^{C}\sum_{k=1}^{N} u_{i,k}\|x_k - v_i\|_2^2 + \lambda^{-1}\sum_{i=1}^{C}\sum_{k=1}^{N} u_{i,k}\log\left(\frac{u_{i,k}}{\alpha_i}\right)$$

$$\text{subject to } \sum_{i=1}^{C} u_{i,k} = 1 \;,\; \sum_{i=1}^{C} \alpha_i = 1 \text{ and } \lambda > 0, \quad \alpha_i > 0$$

| | | | |
|---|---|---|---|
| $N$ | データ数 | $x_k$ | データ数 |
| $C$ | クラスタ数 | $v_i$ | クラスタ中心 |
| $\lambda$ | ファジィ化パラメータ | $u_{i,k}$ | 帰属度 |
| $\alpha_i$ | クラスタサイズ調整変数 | | |

# クラスタリングの最適化問題

## qFCMA

$$\underset{u,v,\alpha}{\text{minimize}} \sum_{i=1}^{C} \sum_{k=1}^{N} (\alpha_i)^{1-m} (u_{i,k})^m \|x_k - v_i\|_2^2 + \frac{\lambda^{-1}}{m-1} \sum_{i=1}^{C} \sum_{k=1}^{N} (\alpha_i)^{1-m} (u_{i,k})^m$$

$$\text{subject to } \sum_{i=1}^{C} u_{i,k} = 1\ ,\ \sum_{i=1}^{C} \alpha_i = 1 \ \text{ and } \ \lambda > 0\ ,\ m > 1\ ,\ \alpha_i > 0$$

| | | | |
|---|---|---|---|
| $N$ | データ数 | $x_k$ | データ数 |
| $C$ | クラスタ数 | $v_i$ | クラスタ中心 |
| $\lambda, m$ | ファジィ化パラメータ | $u_{i,k}$ | 帰属度 |
| $\alpha_i$ | クラスタサイズ調整変数 | | |

# クラスタリングの最適化問題

**sFCMA**

$$\underset{u,v,\alpha}{\text{minimize}} \sum_{i=1}^{C}\sum_{k=1}^{N}(\alpha_i)^{1-m}(u_{i,k})^m\|x_k - v_i\|_2^2$$

$$\text{subject to } \sum_{i=1}^{C} u_{i,k} = 1\ ,\ \sum_{i=1}^{C}\alpha_i = 1 \ \text{ and } \ m > 1\ ,\ \alpha_i > 0$$

| | | | |
|---|---|---|---|
| $N$ | データ数 | $x_k$ | データ数 |
| $C$ | クラスタ数 | $v_i$ | クラスタ中心 |
| $m$ | ファジィ化パラメータ | $u_{i,k}$ | 帰属度 |
| $\alpha$ | クラスタサイズ調整変数 | | |

# 実験方法

1. 人工データ実験
2. 実データ実験
3. 実データ実験で算出した ARI により各手法を評価

# 評価方法

ARI (Adjusted Rand Index)

- $-1$ から $1$ までの範囲で精度評価を行う指標
- $1$ の時に完全一致で $0$ の時にランダム
- ARI の値が高いほど高評価

# 人工データ実験

**使用する人工データ**

- **平均値** $(-1, -1)$, **標準偏差** $(0.5, 0.5)$ **及び平均値** $(-1, -1)$, **標準偏差** $(0.5, 0.5)$ **のガウスサンプリングで生成**
- **データ数**: 100
- **クラス数** : 2

# 人工データ実験のアルゴリズム

1.

# 実験結果:人工データ

## eFCMA

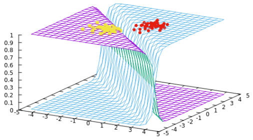

$\lambda = 1$

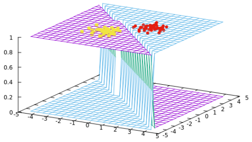

$\lambda = 10000$

## eFCMA の特徴

**パラメータ $\lambda$ を無限大に近づけるほど HCM に近づく**

# 実験結果:人工データ

## sFCMA

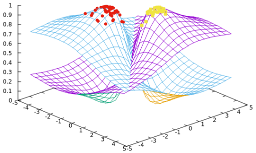


$m = 2$

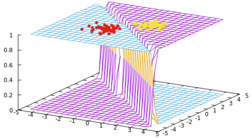


$m = 1.01$

## sFCMA の特徴

**パラメータ $m$ を 1 に近づけるほど HCM に近づく**

# 実験結果:人工データ

## qFCMA

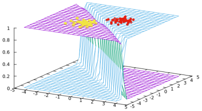

$m = 1.01\ ,\ \lambda = 10$

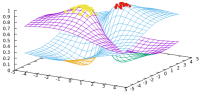

$m = 2\ ,\ \lambda = 10$

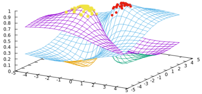

$m = 2\ ,\ \lambda = 10000$

## qFCMA の特徴

- **パラメータ $\lambda$ を無限大に近づけると** sFCMA **に近づく**
- **パラメータ $m$ を** 1 **に近づけると** eFCMA **に近づく**

# 各手法間の関係

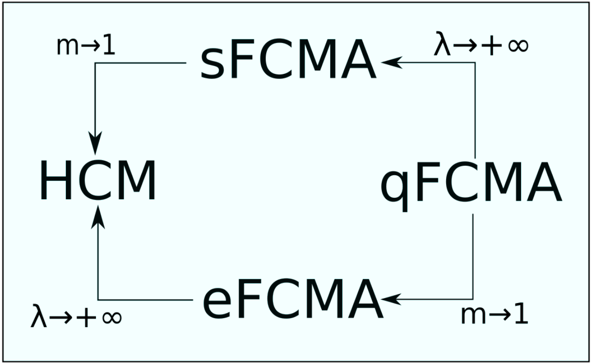

# 実データ実験

User Knowledge Modeling Data Set

- **被験者の勉強時間、試験結果など** 5 **属性を収録したデータ**
- **ソース** : UCI Machine Learning Repository
- **個体数** : 403
- **クラス数** : 4(**非常に低い、低い、中央、高い**)

# 実験条件

**eFCMA**

パラメータ $\lambda$ を 5.0 から 0.1 刻みで 10.0 まで変化させる

**qFCMA**

- パラメータ $\lambda$ を 5.0 から 0.1 刻みで 10.0 まで変化させる
- パラメータ $m$ を 2.0 から 0.01 刻みで 1.01 まで変化させる

**sFCMA**

パラメータ $m$ を 2.0 から 0.01 刻みで 1.01 まで変化させる

# 実データ実験のアルゴリズム

1. 

# 実験結果:実データ

## eFCMA

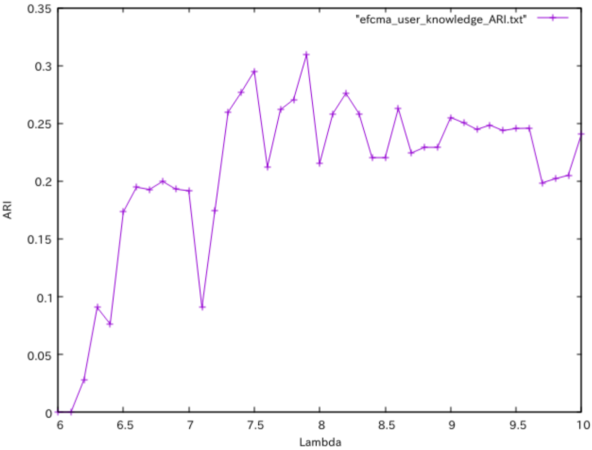


**最高** ARI:

## 実験結果:実データ

qFCMA

**最高** ARI:

# 実験結果:実データ

## sFCMA

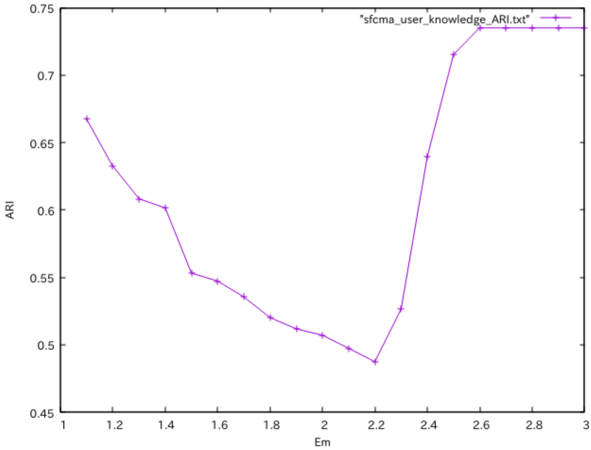


**最高** ARI:

# 実験結果

## 各手法の最高 ARI

| | | |
|---|---|---|
| eFCMA | | $\lambda =$ |
| qFCMA | | $\lambda =,\ m =$ |
| sFCMA | | $m =$ |

## 評価

**sFCMA が最も高評価**

# 考察・課題

## 考察

- sFCMA と eFCMA、qFCMA との差は、エントロピー項の有無。
- エントロピー項を削除したことが計算結果に影響したと考えられる。

## 課題

- 他の実データでも同様の傾向が現れるかどうかの検証。
- エントロピー項が影響する原因及び理由の調査。

# まとめ

## 目的

- 

## 目標

- 

## 実験結果

- sFCMA が高評価となった

## 考察

- エントロピー項を削除したことが計算結果に影響したと考えられる

# 補足:eFCMA の更新式

$$
\begin{aligned}
v_i &= \frac{\sum_{k=1}^{N} u_{i,k} x_k}{\sum_{k=1}^{N} u_{i,k}}, \\
u_{i,k} &= \frac{\pi_i \exp(-\lambda \|x_k - v_i\|_2^2)}{\sum_{j=1}^{C} \alpha_j \exp(-\lambda \|x_k - v_j\|_2^2)}, \\
\alpha_i &= \frac{\sum_{k=1}^{N} u_{i,k}}{N}.
\end{aligned}
$$

# 補足:qFCMA の更新式

$$
\begin{aligned}
v_i &= \frac{\sum_{k=1}^{N}(u_{i,k})^m x_k}{\sum_{k=1}^{N}(u_{i,k})^m}, \\
u_{i,k} &= \frac{\alpha_i(1+\lambda(1-m)\|x_i - v_k\|_2^2)^{\frac{1}{1-m}}}{\sum_{j=1}^{C}\alpha_j(1+\lambda(1-m)\|x_j - v_k\|_2^2)^{\frac{1}{1-m}}}, \\
\alpha_i &= \frac{1}{\sum_{j=1}^{C}\left(\sum_{k=1}^{N}\frac{(u_{j,k})^m(1-\lambda(1-m)d_{j,k})}{(u_i,k)^m(1-\lambda(1-m)d_{i,k})}\right)^{\frac{1}{m}}}.
\end{aligned}
$$

# 補足:sFCMA の更新式

$$
\begin{aligned}
v_i &= \frac{\sum_{k=1}^{N} (u_{i,k})^m x_k}{\sum_{k=1}^{N} (u_{i,k})^m}, \\
u_{i,k} &= \frac{1}{\sum_{j=1}^{c} \frac{\alpha_j}{\alpha_i} \left( \frac{d_{j,k}}{d_{i,k}} \right)^{\frac{1}{1-m}}}, \\
\alpha_i &= \frac{1}{\sum_{j=1}^{C} \left( \sum_{k=1}^{N} \frac{(u_{j,k})^m d_{j,k}}{(u_{i,k})^m d_{i,k}} \right)^{\frac{1}{m}}}.
\end{aligned}
$$